

Clasificación Automática de Golpes en Tenis de Mesa con IMU: Estado de la Cuestión

Miguel Giménez

Resumen—Este artículo presenta una revisión sistemática de la literatura sobre métodos basados en sensores inerciales (IMU) para la clasificación automática de golpes en tenis de mesa, siguiendo la metodología PRISMA 2020. Se realizaron búsquedas en IEEE Xplore, Scopus, Elicit y Semantic Scholar con dos cadenas booleanas complementarias, e incorporando referencias adicionales mediante Connected Papers. Tras eliminar 40 duplicados sobre ~108 registros brutos, se cribaron 68 registros únicos, de los que 16 estudios fueron finalmente incluidos en la síntesis. Los trabajos analizados demuestran que las IMU de 6–9 ejes, colocadas en la pala, la muñeca o el antebrazo y combinadas con clasificadores supervisados (SVM —*Support Vector Machine*—, Random Forest, CNN —*Convolutional Neural Network*— y LSTM —*Long Short-Term Memory*—), alcanzan precisiones entre el 85,7 % y el 99,6 % para conjuntos de 3–8 clases de golpe. Las principales brechas detectadas son la escasa validación con jugadores amateurs en entorno real de juego, la falta de comparativas directas entre ubicaciones del sensor, y la baja reproducibilidad: solo 3 de los 16 estudios publican código o datos abiertos. Estos hallazgos fundamentan el diseño de un sistema embebido basado en Arduino Nano 33 BLE Sense con clasificación en tiempo real mediante Edge Impulse.

Palabras clave—tenis de mesa, clasificación de golpes, IMU, acelerómetro, giroscopio, aprendizaje automático, CNN, LSTM, sistemas embebidos, wearable, revisión sistemática, PRISMA

I. INTRODUCCIÓN

LA clasificación automática de golpes en tenis de mesa mediante sensores inerciales representa un área de creciente interés dentro de las redes de sensores y el análisis de movimiento en deportes. Este tipo de sistemas permite monitorizar la actividad de los jugadores en tiempo real, facilitando aplicaciones como el entrenamiento asistido, la mejora del rendimiento y el análisis técnico sin necesidad de sistemas complejos como cámaras [1].

El uso de dispositivos embebidos con IMU, como los integrados en plataformas de bajo coste tipo Arduino Nano 33 BLE Sense, permite desarrollar soluciones portátiles, accesibles y energéticamente eficientes. La aplicación de técnicas de aprendizaje automático supervisado sobre señales de acelerómetro y giroscopio abre la puerta a sistemas capaces de reconocer patrones de movimiento con alta precisión [8], [13].

Este tema es relevante tanto a nivel académico como práctico, ya que combina tecnologías clave como sensores

inerciales, sistemas embebidos y aprendizaje automático, con aplicaciones directas en el ámbito deportivo y del Internet de las Cosas (IoT). A pesar del creciente número de publicaciones en esta área, la literatura presenta una falta de revisiones sistemáticas recientes que sinteticen de forma cuantitativa los resultados obtenidos, comparen configuraciones de sensor y algoritmos, e identifiquen de forma estructurada las principales limitaciones metodológicas.

Trabajos previos han demostrado que IMU colocadas en la pala o en la muñeca, combinadas con clasificadores supervisados como SVM, Random Forest o redes neuronales, alcanzan precisiones típicamente superiores al 90 % en entornos controlados para tareas de clasificación de 3 a 8 tipos de golpe [1], [3], [8]. Sin embargo, la mayoría de estos estudios presentan limitaciones relevantes: los experimentos se realizan offline en PC sin inferencia en tiempo real, los datasets son pequeños (frecuentemente menos de 10 participantes) y los sujetos suelen ser jugadores de nivel avanzado o profesional, lo que limita la generalización a jugadores amateurs. Además, no existe un consenso establecido sobre la ubicación óptima del sensor ni sobre el algoritmo más adecuado cuando el requisito es el despliegue en hardware embebido de bajo coste.

El objetivo de este trabajo es cubrir ese vacío mediante un Estado de la Cuestión (EdC) siguiendo los estándares PRISMA 2020 [17]. Además, se definen criterios explícitos de inclusión y exclusión basados en el marco PICOS, así como métricas de evaluación estandarizadas (precisión y F1-score) para garantizar la comparabilidad entre estudios. La pregunta de investigación que guía la revisión es:

¿Qué métodos basados en sensores inerciales (IMU) son más efectivos para la clasificación de distintos tipos de golpe en tenis de mesa en jugadores amateurs?

El resto del artículo se organiza de la siguiente manera: la Sección II describe el protocolo de revisión sistemática; la Sección III presenta los estudios incluidos y su síntesis comparativa; la Sección IV discute las tendencias, limitaciones y brechas identificadas; y la Sección V recoge las conclusiones y trabajo futuro.

II. METODOLOGÍA

A. Marco PICOS y Criterios de Inclusión/Exclusión

La estrategia de búsqueda y los criterios de inclusión/exclusión se definieron a priori mediante el marco PICOS [17]:

M. Giménez pertenece al Máster Universitario en Ingeniería Electrónica, Escuela de Ingeniería y Arquitectura, Universidad de Zaragoza, 50018 Zaragoza, España (e-mail: 760599@unizar.es).

Manuscrito preparado como Estado de la Cuestión (Redes de Sensores, 2025–2026). Se utilizaron herramientas de IA (Claude, Gemini, Elicit) en búsqueda, cribado y extracción. Todo el contenido fue verificado y redactado por el autor.

TABLA I
RESULTADOS DE BÚSQUEDA POR BASE DE DATOS Y CADENA

Base de datos	Cadena	<i>n</i>
IEEE Xplore	A	20
Scopus	A	11
Elicit	A	15
Semantic Scholar	A (top-25/250)	25
IEEE Xplore	B	4
Scopus	B	7
Elicit	B	8
Semantic Scholar	B	1
Connected Papers	encadenada	~26
Total bruto		~108
Duplicados eliminados		40
Registros únicos cribados		68

- **P (Población):** jugadores de tenis de mesa (amateurs o mixtos) en entorno *indoor*, durante sesiones de entrenamiento.
- **I (Intervención):** sistema basado en una IMU (≥ 6 ejes) en dispositivo embebido con clasificador supervisado (SVM, Random Forest, CNN, LSTM).
- **C (Comparador):** C1 — visión artificial; C2 — umbrales sobre IMU; C3 — ubicación alternativa del sensor.
- **O (Outcome):** precisión $\geq 85\%$ y/o F1-score reportados explícitamente.
- **S (Study design):** validación con datos reales (Nivel 1 o 2). Se excluyen simulaciones.

A partir de este marco, se derivaron los siguientes criterios operacionales: Se incluyeron estudios con validación experimental real, métricas cuantitativas (accuracy y/o F1-score) y comparación con al menos un método *baseline*. Se excluyeron trabajos basados únicamente en simulación, sin métricas comparables, exclusivamente de visión artificial, o con muestra $n < 2$ participantes.

B. Estrategia de Búsqueda

Se ejecutaron dos cadenas booleanas (A y B) en IEEE Xplore, Scopus, Elicit y Semantic Scholar durante febrero–abril de 2026, cubriendo el período 2015–2026. Adicionalmente, se empleó Connected Papers con papers semilla para identificar referencias no recuperadas por palabras clave. La Tabla I resume los resultados por base de datos.

Cadena A:

```
("table tennis" OR "ping pong" OR
"ping-pong") AND ("IMU" OR "inertial
sensor" OR "accelerometer" OR "gyroscope")
AND ("stroke classification" OR "motion
classification" OR "gesture recognition")
AND ("machine learning" OR "deep learning"
OR "SVM" OR "random forest")
```

Cadena B:

```
("table tennis" OR "ping pong") AND
("wearable sensor" OR "inertial sensor" OR
"IMU") AND ("stroke classification" OR "shot
classification" OR "sport analytics") AND
("machine learning" OR "supervised learning"
OR "classification algorithm")
```

C. Proceso de Cribado y Diagrama PRISMA

El cribado se realizó en dos etapas. En la primera (título/abstract), se excluyeron 35 registros mediante los cri-

TABLA II
CÓDIGOS DE EXCLUSIÓN PRISMA Y FRECUENCIA

Código	Descripción	<i>n</i>
WF	Fuera del alcance (deporte $\neq$ TT, tecnología excluida)	32
NR-1	No relevante en cribado título/abstract	3
NR-2	No relevante al leer texto completo	11
LR-2	Muestra insuficiente o sin comparador	2
LR-3	Métricas no estándar	1
LR-4	Texto inaccesible	1
SER	Revisión sistemática existente	1
Total excluidos		51

terios WF y NR-1. En la segunda etapa (texto completo), se excluyeron 16 registros adicionales con los criterios NR-2, LR-2, LR-3, LR-4 y SER. Los 16 estudios restantes constituyen la síntesis final. La Figura 1 ilustra el diagrama PRISMA 2020 y la Tabla II define los códigos empleados.

D. Extracción de datos y evaluación de calidad

De cada estudio se extrajeron: tipo de sensor, plataforma, posición, algoritmo, métricas cuantitativas, tamaño del dataset y número de participantes. La calidad metodológica se evaluó mediante criterios adaptados del marco GRADE.

III. RESULTADOS

A. Descripción General de los Estudios Incluidos

La síntesis comprende 16 estudios publicados entre 2015 y 2025, con una concentración notable en el período 2019–2025 ($n = 15$). La Tabla III presenta la información extraída de cada estudio. Atendiendo a la ubicación del sensor, los trabajos se distribuyen del siguiente modo: IMU en la pala o mango de la raqueta ($n = 4$, 25%), IMU en la muñeca o reloj inteligente ($n = 8$, 50%), red de sensores corporales o antebrazo ($n = 2$, 12,5%), dorso de la mano ($n = 1$) y fusión multisensor cámara + IMU ($n = 1$). El número de clases de golpe varía entre 2 y 8, siendo el rango 3–6 el más frecuente. En cuanto al tamaño muestral, el 62,5% de los estudios incluye ≥ 10 participantes; los dos extremos inferiores son Vajjula [16] y Wieland & Pankratius [10], con 2 sujetos cada uno, aunque este último compensa la baja n con 3 770 eventos registrados.

B. IMU en la Pala o Mango de la Raqueta

La colocación del sensor directamente sobre la pala o su mango es la configuración que ofrece la señal más directa del movimiento del golpe, al estar el sensor acoplado rígidamente al instrumento de impacto.

Blank et al. [1], en el trabajo seminal del área, colocaron una plataforma miPod de 6 DOF (*Degrees of Freedom*) en la pala de 10 jugadores de distinto nivel y evaluaron seis clasificadores sobre 1 982 golpes válidos de 8 clases. El mejor resultado lo obtuvo SVM con kernel RBF (accuracy 96,7%, sensibilidad de detección 95,7%), aunque los autores señalan que su elevado coste computacional lo hace poco adecuado para implementaciones embebidas. Tabrizi et al. [4] emplearon un sensor BNO055 de 9 DOF montado en el centro de la hoja




Fig. 1. Diagrama de flujo PRISMA 2020. De 68 registros únicos cribados se incluyeron 16 estudios en la síntesis final.

de la raqueta para clasificar 3 tipos de golpe de derecha con 16 participantes. El modelo LSTM superó a 2D-CNN y RBF-SVM, alcanzando una exactitud de validación del 98,36 % y un F1-score de 99,02 %, convirtiéndose en el resultado de referencia del conjunto. El mismo grupo [7] extendió el trabajo hacia la evaluación de la calidad del golpe mediante regresión (RMSE 3,39), una tarea complementaria de mayor complejidad analítica. Sheu et al. [15], más recientemente, integraron un sensor ICM-20948 de 9 ejes en el mango de la raqueta y aplicaron una CNN de 12 capas con extracción de características en frecuencia mediante STFT (*Short-Time Fourier Transform*), clasificando 6 tipos de golpe con una exactitud del 92 % en validación; los autores identificaron confusión entre FH Stroke y BH Cut debido a la similitud espectral de sus señales.

La ventaja principal de esta configuración es la alta relación señal-ruido para el gesto de golpe; su inconveniente es la mayor intrusividad (modifica el equilibrio de la pala) y la necesidad de un diseño mecánico robusto.

C. IMU en la Muñeca o Reloj Inteligente

La ubicación del sensor en la muñeca, frecuentemente integrado en un smartwatch comercial, es la más representada en la literatura ($n = 8$), lo que refleja la proliferación de dispositivos wearable de consumo.

Zhang et al. [3] y Fu et al. [2] utilizaron el mismo dataset de 12 voluntarios y 2 275 muestras de 8 clases de golpe, recogidos

con un smartwatch Android de 9 ejes. Zhang et al. compararon seis clasificadores clásicos más una CNN simple, obteniendo los mejores resultados con Random Forest (accuracy 97,80 %, F1 97,86 %), lo que establece RF como *baseline* robusto en configuraciones de muñeca. Fu et al. se centraron en una arquitectura CNN con capa de *dropout* personalizada, obteniendo un 95,46 % de exactitud con los tres ejes combinados. Tan & Xie [5] presentaron el único estudio con sensor de 3 ejes únicamente (acelerómetro, sin giroscopio), empleando un clasificador *ensemble* de árboles difusos combinado con TCN, alcanzando una accuracy del 91 % sobre 4 clases con 20 participantes. Este resultado, el más bajo del subgrupo, sugiere que la ausencia del giroscopio limita la discriminación de golpes con patrones similares de aceleración pero distinta velocidad angular.

Ferreira et al. [11] emplearon el acelerómetro y giroscopio de un Apple Watch muestreados a 50 Hz para clasificar 5 tipos de golpe más una clase de reposo en 15 atletas de nivel nacional. La arquitectura ConvLSTM superó a CNN-LSTM y LSTM estándar, obteniendo un F1-score de 97,33 %; la principal confusión se produjo entre Flip BH y Topspin BH. Wieland & Pankratius [10] son los únicos que integraron conocimiento del dominio explícito (secuencias de golpes válidas en tenis de mesa) mediante una máquina de estados finitos (SSSM) acoplada a un clasificador LSTM en cascada, obteniendo un F1 de 97,27 % sobre 8 clases ejecutado íntegramente en un smartwatch Fossil Gen 5E.

TABLA III
TABLA COMPARATIVA DE LOS 16 ESTUDIOS INCLUIDOS

Ref.	Autores, Año	Sensor Posición /	Plataforma HW	Algoritmo	Clases	Sujetos	Métrica principal
[1]	Blank et al., 2015	miPod 6-ejes, pala	Flash interno (offline)	SVM-RBF (mejor de 6)	8	10	Acc. 96,7 %
[3]	Zhang et al., 2019	Smartwatch Android, 9-ejes, muñeca	Smartwatch + PC	Random Forest (mejor de 6)	8	12	Acc. 97,80 %; F1 97,86 %
[2]	Fu et al., 2019	HUAWEI Watch 2, 9-ejes, muñeca	Smartwatch + PC	CNN (dropout personalizado)	8	12	Acc. 95,46 %
[4]	Tabrizi et al., 2020	BNO055, pala	PC (i7-8700k + GPU)	LSTM (mejor; vs CNN, SVM)	3	16	Acc. 98,36 %; F1 99,02 %
[5]	Tan & Xie, 2021	Brazaletes 3-ejes, muñeca	Microproc. embebido (IIC)	Ensemble DT difuso + TCN	4	20	Acc. 91 %
[6]	Abdelsalam et al., 2021	Cámara IR + smart band (acc+gyro)	Servidor interno	FastDTW	2	8 prof.	Acc. 97,2 %; F1 0,92
[7]	Tabrizi et al., 2021	BNO055, pala	PC (offline)	LSTM modificado (regresión)	3	16	RMSE 3,39
[11]	Ferreira et al., 2022	Apple Watch, 6-ejes, muñeca	Apple Watch + MacBook Pro	ConvLSTM (mejor de 3)	5+rest	15	F1 97,33 %
[10]	Wieland & Pankratius, 2023	Fossil Gen5E, 9-ejes, muñeca	Smartwatch (on-device)	LSTM cascada + SSSM	8	2 ($n=3\,770$)	F1 97,27 %
[12]	Ezzeldin et al., 2023	Acc+gyro, smartphone, muñeca	Smartphone	P-Dollar jerárquico	6	N/D	Acc. 88 %
[9]	Ghosh et al., 2023	2×MPU-6050, antebrazo+hombro	Arduino Nano 33 BLE	NN densa + QAT	3	5–6	Acc. 90,7 % (85,7 % QAT)
[8]	Yen et al., 2023	MPU-6050 6-ejes, dorso mano	Raspberry Pi 3	CNN multiescala	4	20	Acc. 99,58 %; F1 99,16 %
[13]	Liu et al., 2019	ADIS16448 9-ejes, BSN cuerpo	Nodos custom + NRF24L01	PCA + SVM	5	9	Acc. 97,41 %; F1 0,974
[14]	Song et al., 2025	MPU-6050, muñeca/cuerpo	ATmega328P (100 Hz)	DAGSVM + PCA	6	10	Acc. 97,77 %
[15]	Sheu et al., 2025	ICM-20948 9-ejes, pala/mango	PC (offline)	CNN 12 capas + STFT	6	N/D (> 4,000 ev.)	Acc. 92 % (val.)
[16]	Vajjula, 2025	LSM6DS3 9-ejes, muñeca	Arduino Nano 33 IoT	Random Forest (on-device)	6	2	Acc. >94 %

Ezzeldin et al. [12] propusieron un clasificador P-Dollar jerárquico sobre smartphone que distingue en primer nivel FH/BH y en segundo nivel el subtipo de error técnico, alcanzando un 88 % de accuracy con una latencia de 4 s. Song et al. [14] presentaron un DAGSVM con reducción PCA (*Principal Component Analysis*) sobre datos de un MPU-6050 a 100 Hz en un ATmega328P, logrando un 97,77 % de accuracy sobre 6 clases en 10 atletas profesionales. Por último, Vajjula [16] implementó un Random Forest en tiempo real sobre un Arduino Nano 33 IoT montado en la muñeca, clasificando 6 clases con accuracy >94 %: es, junto con Wieland [10], el único estudio con inferencia completamente on-device en hardware embebido.

D. Redes de Sensores Corporales y Antebrazo

Dos estudios adoptan configuraciones con múltiples nodos de sensores distribuidos en el cuerpo. Liu et al. [13] desplegaron una BSN (*Body Sensor Network*) con nodos IMU ADIS16448 de 9 ejes en brazo, hombro y muñeca, conectados sin hilos mediante NRF24L01 a 2,4 GHz. La clasificación mediante PCA + SVM alcanzó un 97,41 % de accuracy y F1 0,974 sobre 5 clases en 9 jugadores, aunque el golpe FH drive presentó la mayor tasa de error por sus características cinemáticas menos diferenciadas. Ghosh et al. [9] colocaron

dos IMU MPU-6050 en antebrazo y hombro, conectadas a un Arduino Nano para adquisición y desplegadas en un Arduino Nano 33 BLE para inferencia. La red neuronal densa de 3 capas con cuantización QAT (*Quantization-Aware Training*) obtuvo un 90,7 % de accuracy en el modelo original y un 85,7 % en el modelo cuantizado, que constituye la métrica mínima del conjunto. Esta degradación de 5 puntos porcentuales por la cuantización ilustra el coste de la optimización para despliegue embebido.

E. Dorso de la Mano y Fusión Multisensor

Yen et al. [8] colocaron un MPU-6050 de 6 DOF en el dorso de la mano de 20 participantes y diseñaron una CNN multiescala con dos tamaños de kernel para fusionar características a distintas escalas temporales. El resultado (accuracy 99,58 %, F1 99,16 %) es el más alto del conjunto; sin embargo, la evaluación en entorno de laboratorio con sensor fijado en posición específica limita la generalización a condiciones de juego real, donde la holgura del ajuste degrada significativamente el rendimiento.

Abdelsalam et al. [6] presentan el único estudio con fusión cámara + IMU: una cámara de profundidad IR de primera generación se combina con una banda inteligente (acelerómetro + giroscopio) en la muñeca mediante ajuste de

TABLA IV
EVALUACIÓN DE CALIDAD ADAPTADA DE COCHRANE (% POR
RESPUESTA, $n = 16$)

#	Ítem	Sí	Parc.	No
1	Validación datos reales	100	0	0
2	Muestra suficiente	81	13	6
3	Métricas estándar	100	0	0
4	Comparación baseline	75	13	13
5	Reproducibilidad	19	0	81
6	Limitaciones declaradas	56	0	44
7	Generalizable	13	38	50
8	Conflictos de interés	63	0	38

curvas, filtro de Kalman y clasificación FastDTW. El sistema alcanza un 97,2% de accuracy sobre 2 clases (FH/BH) en 8 jugadores profesionales. Aunque los resultados son competitivos, la dependencia de una cámara IR fija en el entorno aleja esta solución del objetivo de sistema portable y de bajo coste.

F. Análisis de Tendencias y Estadísticos Globales

La distribución de algoritmos muestra un empate entre las tres familias dominantes: LSTM y variantes ($n = 4$, 25%), CNN y variantes ($n = 4$, 25%) y SVM y variantes ($n = 4$, 25%), con Random Forest en tercer lugar ($n = 3$, 19%). Las precisiones reportadas oscilan entre el 85,7% [9] y el 99,58% [8], con una mediana aproximada del 97%. El F1-score se reporta en 9 de los 16 estudios; los 7 restantes informan solo accuracy.

Solo dos estudios ejecutan la inferencia íntegramente en dispositivo embebido en tiempo real [9], [16]; el resto procesa los datos offline en PC, lo que supone una barrera relevante para la traslación a aplicaciones de entrenamiento portátil. La Tabla IV resume la evaluación de los 8 ítems de calidad metodológica.

Todos los estudios validan sobre datos reales (ítem 1: 100%) y reportan métricas estándar (ítem 3: 100%), lo que garantiza la homogeneidad mínima de la síntesis. Sin embargo, el 81% no publica código ni datos (ítem 5), el 44% no declara limitaciones (ítem 6) y el 50% presenta limitaciones de generalización a perfiles de usuario diversos (ítem 7), señales claras del margen de mejora metodológica del campo.

IV. DISCUSIÓN

A. Tendencias Identificadas

Los resultados muestran que no existe un algoritmo dominante único: LSTM, CNN y SVM están representados en igual medida ($n = 4$ cada uno), con Random Forest como cuarta opción relevante ($n = 3$). Esta distribución refleja que el problema de clasificación de golpes admite soluciones eficaces desde distintas familias de modelos, y que la elección óptima depende en gran medida del hardware disponible y del requisito o no de inferencia en tiempo real.

En cuanto a la evolución temporal, los trabajos más recientes (2022–2025) tienden hacia arquitecturas secuenciales o híbridas (ConvLSTM [11], LSTM en cascada con máquinas de estado [10], CNN con STFT [15]) que capturan mejor la dinámica temporal del gesto. Sin embargo, esta mayor

capacidad expresiva conlleva un coste computacional que dificulta la inferencia en tiempo real sobre microcontroladores de gama baja. Por el contrario, Random Forest y SVM permiten inferencia embebida con latencias reducidas [16], [13], lo que los convierte en candidatos preferentes cuando el requisito es el despliegue en hardware de bajo coste.

B. Comparativa de los Sistemas Embebidos

Dos estudios ejecutan la clasificación íntegramente en dispositivo sin PC auxiliar, y ambos son especialmente relevantes para el sistema propuesto en este EdC. Ghosh et al. [9] desplegaron una red neuronal densa con cuantización QAT en un Arduino Nano 33 BLE, obteniendo un 90,7% de accuracy con el modelo original y un 85,7% tras la cuantización. Esta caída de 5 puntos porcentuales ilustra el coste real de la optimización para inferencia embebida y fija el límite inferior de rendimiento esperable con redes neuronales cuantizadas. Vajjula [16], por su parte, implementó un Random Forest on-device en un Arduino Nano 33 IoT (hardware equivalente al Arduino Nano 33 BLE Sense del presente trabajo), alcanzando una accuracy >94% sobre 6 clases. Aunque el dataset es reducido (2 sujetos), este resultado valida la viabilidad del enfoque RF + Edge Impulse en la plataforma objetivo y establece el 94% como objetivo de referencia conservador.

C. Brechas y Limitaciones Detectadas

Se identifican cuatro brechas principales a partir del análisis conjunto de los estudios y de la evaluación de calidad (Tabla IV).

Primera — reproducibilidad: el 81% de los estudios no publica código ni datos en repositorios accesibles (ítem 5). Esta es la limitación metodológica más grave del campo, ya que impide replicar resultados, comparar sistemas bajo las mismas condiciones y construir sobre el trabajo previo de forma acumulativa.

Segunda — generalización: el 50% de los estudios obtiene una puntuación insuficiente en el ítem de generalización (ítem 7). Los datasets suelen ser homogéneos en cuanto al nivel de juego (mayoritariamente profesionales o nivel nacional), al tipo de agarre (casi exclusivamente *shakehand*) y al entorno (laboratorio controlado). En particular, ningún estudio valida exclusivamente con jugadores amateurs, que es precisamente la población objetivo del PICOS de este EdC. El trabajo más cercano es Blank et al. [1], que incluye jugadores de nivel mixto, amateur y profesional.

Tercera — comparativa de ubicación del sensor: ningún estudio evalúa bajo las mismas condiciones experimentales la ubicación del sensor en la pala frente a la muñeca para el mismo conjunto de clases. Esto significa que la pregunta C3 del PICOS queda sin respuesta directa en la literatura: los trabajos con sensor en pala [1], [4], [15] y los de muñeca [3], [11], [14] no son directamente comparables por diferir en número de clases, sujetos y protocolo.

Cuarta — declaración de limitaciones: el 50% de los estudios no incluye una sección explícita de limitaciones (ítem 6), lo que indica un posible sesgo de publicación hacia resultados favorables y dificulta la interpretación crítica de las métricas reportadas.

D. Implicaciones para el Sistema Propuesto

La revisión permite derivar las siguientes recomendaciones de diseño para el sistema basado en Arduino Nano 33 BLE Sense:

(a) *Ubicación del sensor*: la pala es la ubicación con mayor evidencia acumulada en cuanto a precisión [4] y especificidad de señal. La muñeca ofrece mayor comodidad pero captura también movimientos del brazo no relacionados con el golpe.

(b) *Algoritmo*: Random Forest es el candidato más adecuado para inferencia embebida con Edge Impulse, por su viabilidad demostrada en hardware equivalente [16] y su rendimiento competitivo frente a SVM y redes neuronales en configuraciones de muñeca [3].

(c) *Dataset*: recoger al menos 500 muestras por clase con ≥ 10 participantes amateurs para obtener resultados comparables con el estado del arte y cubrir el gap de generalización identificado. Muestrear a 100 Hz con ventanas de 1–2 s y solapamiento del 50 %, configuración predominante en los estudios analizados.

(d) *Métricas*: reportar tanto accuracy como F1-score por clase (solo el 56 % de los estudios incluidos reporta ambas), publicar el código y los datos en repositorio público para contribuir a mejorar la reproducibilidad del campo.

V. CONCLUSIONES

Se ha presentado una revisión sistemática de la literatura sobre clasificación de golpes en tenis de mesa mediante sensores inerciales, siguiendo PRISMA 2020. De 68 registros únicos cribados se han incluido 16 estudios (2015–2025).

Los resultados demuestran que las IMU de 6–9 ejes en pala o muñeca, combinadas con clasificadores supervisados, alcanzan precisiones entre el 85,7 % y el 99,6 % para 2–8 clases de golpe. LSTM y CNN son los algoritmos con mayores precisiones en los estudios recientes; Random Forest ofrece el mejor compromiso entre rendimiento y viabilidad de inferencia embebida en tiempo real.

En respuesta a la pregunta de investigación, los métodos más efectivos dependen del requisito de despliegue: LSTM [4] y CNN [8] maximizan la precisión (hasta 99,58 %) en procesamiento offline, mientras que Random Forest [3], [16] ofrece el mejor compromiso entre rendimiento y viabilidad en hardware embebido de bajo coste en tiempo real. Ningún estudio valida exclusivamente con jugadores amateurs, que es precisamente la población objetivo de este EdC.

Las principales brechas son la baja reproducibilidad (81 % sin datos ni código públicos), la falta de generalización a perfiles de usuario diversos y la ausencia de comparativas directas entre ubicaciones de sensor.

Estos hallazgos fundamentan el diseño de un sistema embebido basado en Arduino Nano 33 BLE Sense con IMU en la pala y clasificador Random Forest + Edge Impulse, con el objetivo de alcanzar una precisión ≥ 94 % sobre al menos 4 clases de golpe con datos de jugadores amateurs en condiciones reales de entrenamiento.

Este trabajo abre oportunidades futuras para validar sistemas portátiles en escenarios reales de juego, evaluar la transferencia de modelos entre jugadores, e integrar retroalimentación automática en plataformas de entrenamiento accesibles.

AGRADECIMIENTOS

El autor agradece al Departamento de Ingeniería Electrónica e Informática de la Universidad de Zaragoza el acceso a los recursos bibliográficos. Se han utilizado como herramientas de asistencia Claude (Anthropic), Gemini (Google) y Elicit en las fases de búsqueda, cribado y extracción de datos. Todo el contenido ha sido verificado, reescrito y validado por el autor, quien asume plena responsabilidad sobre la exactitud y originalidad del trabajo.

REFERENCES

- [1] P. Blank, J. Hoßbach, D. Schuldhaus, and B. M. Eskofier, "Sensor-based stroke detection and stroke type classification in table tennis," in *Proc. 2015 ACM Int. Symp. Wearable Computers (ISWC)*, Osaka, Japan, 2015, pp. 93–100.
- [2] Z. Fu, K.-I. Shu, and H. Zhang, "Ping pong motion recognition based on smart watch," *Advances in Computer Science Research*, vol. 87, pp. 617–625, 2019.
- [3] H. Zhang, Z. Fu, and K.-I. Shu, "Recognizing ping-pong motions using inertial data based on machine learning classification algorithms," *IEEE Access*, vol. 7, pp. 167055–167064, 2019.
- [4] S. S. Tabrizi, S. Pashazadeh, and V. Javani, "Comparative study of table tennis forehand strokes classification using deep learning and SVM," *IEEE Sensors Journal*, vol. 20, no. 22, pp. 13552–13561, 2020.
- [5] F. Tan and X. Xie, "Recognition technology of athlete's limb movement combined based on the integrated learning algorithm," *Journal of Sensors*, vol. 2021, Art. no. 3057557, 2021.
- [6] H. Hegazy, M. Abdelsalam, M. Hussien, S. Elmosalamy, Y. Hassan, A. Nabil, and A. Atia, "Multi-sensor fusion for online detection and classification of table tennis strokes," *Int. Journal of Intelligent Engineering and Systems*, vol. 14, no. 2, pp. 201–210, 2021.
- [7] S. S. Tabrizi, S. Pashazadeh, and V. Javani, "A deep learning approach for table tennis forehand stroke evaluation system using an IMU sensor," *Computational Intelligence and Neuroscience*, vol. 2021, Art. ID 5584756, 2021.
- [8] C.-T. Yen, T.-Y. Chen, U.-H. Chen, G.-C. Wang, and Z.-X. Chen, "Feature fusion-based deep learning network to recognize table tennis actions," *Computers, Materials & Continua*, vol. 74, no. 1, pp. 83–100, 2023.
- [9] S. Ghosh, Y. Gholap, and S. Tallur, "Wearable sensing module for table tennis stroke detection," in *Proc. 2023 IEEE Applied Sensing Conference (APSCON)*, 2023.
- [10] C. Wieland and V. Pankratius, "Domain-knowledge enhanced machine learning for table tennis stroke characterization," in *Proc. 2023 IEEE World AI IoT Congress (AIoT)*, 2023.
- [11] N. M. Ferreira, J. M. Torres, P. Sobral, R. Moreira, and C. Soares, "Classification of table tennis strokes in wearable device using deep learning," in *Proc. 14th Int. Conf. Agents and Artificial Intelligence (ICAART 2022)*, vol. 3, pp. 629–636, 2022.
- [12] M. Ezzeldin, A. S. Ghoneim, L. Abdelhamid, and A. Atia, "On understanding Sports-HAR: Hierarchical, mobile, multi-sensor based classification of table-tennis strokes," in *Proc. 2023 Intelligent Methods, Systems, and Applications (IMSA)*, Cairo, Egypt, 2023, pp. 142–148.
- [13] R. Liu, Z. Wang, X. Shi, H. Zhao, S. Qiu, J. Li, and N. Yang, "Table tennis stroke recognition based on body sensor network," in *Internet and Distributed Computing Systems (IDCS 2019)*, LNCS 11874, 2019, pp. 1–10.
- [14] Y. Song, S. Zhang, Y. Wang, and Z. Shi, "AI and statistical theory-driven wearable system for intelligent recognition of professional table tennis skills," *Modelling and Simulation in Engineering*, vol. 2025, Art. no. 5998003, 2025.
- [15] Y.-H. Sheu, T.-H. Tai, and T.-Y. Chen, "Application of a 9-axis motion tracking device and STFT for table tennis stroke recognition," in *Proc. 2025 IEEE Int. Conf. Consumer Electronics – Taiwan (ICCE-Taiwan)*, Yunlin, Taiwan, 2025.
- [16] N. V. Vajjala, "Table tennis stroke classification using a wrist-mounted IMU," Dept. of Electrical and Computer Engineering, George Mason University, Tech. Rep. 10.13021/MARS/14857, May 2025.
- [17] R. Casas, "Guía Metodológica para el Estado de la Cuestión Científico con Herramientas de IA Actuales — Redes de Sensores," Escuela de Ingeniería y Arquitectura, Universidad de Zaragoza, Ed. 2025.